UTS Project: Multi-Dataset Information Retrieval System (CLI-Based)

Disusun untuk Memenuhi Tugas Mata Kuliah Praktikum Penelusuran Informasi

OLEH:

Kelompok 3

Andrea Widi	2408107010083
Khalisha Ufairah	2408107010084
Arsha Alifa Mahmud	2408107010095

PROGRAM STUDI INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA

2026

1. Pendahuluan

1.1 Latar Belakang

Information Retrieval (IR) adalah proses menemukan dokumen yang relevan dengan kebutuhan informasi pengguna dari koleksi dokumen yang besar. Mesin pencari modern, perpustakaan digital, dan repositori karya ilmiah memakai prinsip yang sama: dokumen diubah menjadi representasi yang dapat dibandingkan, disimpan dalam struktur index, lalu diurutkan berdasarkan kemiripannya dengan query. Pada proyek UTS ini, tim membangun sistem IR berbasis Command-Line Interface (CLI) yang mengintegrasikan seluruh tahapan tersebut pada data teks berbahasa Indonesia yang nyata.

1.2 Tujuan

(1) Memahami pipeline sistem penelusuran informasi dari preprocessing hingga ranking; (2) mengimplementasikan Vector Space Model dengan representasi Bag of Words (BoW) dan cosine similarity; (3) memakai Whoosh untuk indexing dan searching; (4) menguji kualitas pencarian lintas sumber teks yang beragam.

1.3 Dataset

Sistem memakai lima dataset yang digabung dalam satu koleksi. Setiap dataset berformat CSV dengan dua kolom, yaitu *judul* dan *konten*.

Dataset	**Sumber / Karakter**	**Jumlah dokumen**	**Rata-rata kata**
etd-usk	Tesis/disertasi Universitas Syiah Kuala	10.000	205
etd-ugm	Tesis/disertasi Universitas Gadjah Mada	10.000	229
kompas	Berita harian nasional	10.000	307
tempo	Majalah berita dan opini	10.000	392
mojok	Artikel populer dan satir	9.484	801
Total		**49.484**	

Rata-rata kata dihitung dari kolom konten mentah. Tidak ditemukan nilai kosong maupun dokumen duplikat pada kelima file.

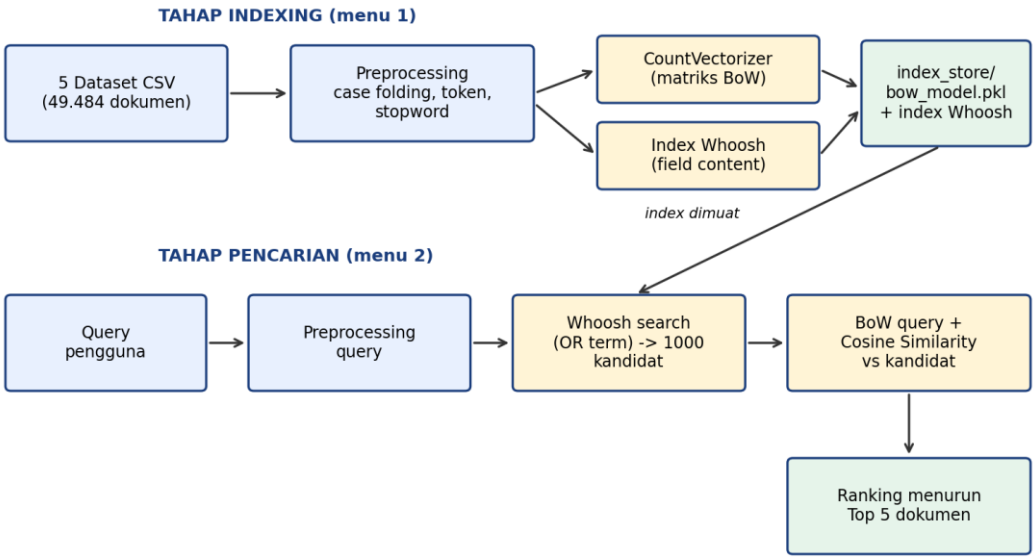
1.4 Batasan

Sistem hanya memakai library Python standar, scikit-learn, Whoosh, dan pandas. Antarmuka berupa CLI interaktif dan sistem menampilkan lima dokumen teratas untuk setiap query.

2. Desain Sistem dan Arsitektur

2.1 Alur Sistem

Sistem terdiri dari dua tahap. Pada tahap indexing (menu [1]), seluruh dokumen dimuat, dipreprocess, diubah menjadi matriks BoW, dan diindeks ke Whoosh. Pada tahap pencarian (menu [2]), query pengguna dipreprocess dengan pipeline yang sama, Whoosh mengambil dokumen kandidat, lalu kandidat diurutkan ulang menggunakan cosine similarity pada ruang BoW.



Gambar 1. Arsitektur sistem IR

2.2 Komponen

Modul	**Tanggung jawab**
main.py	CLI interaktif dengan menu [1] Load & Index, [2] Search, [3] Exit.
config.py	Konfigurasi path, nama dataset, top-N, jumlah kandidat, opsi stemming.
ir/data_loader.py	Memuat CSV tiap dataset dengan pandas, membuang baris kosong/duplikat, menambah kolom dataset.
ir/preprocessing.py	Case folding, tokenisasi, stopword removal, stemming ringan opsional.
ir/stopwords_id.py	Daftar stopword Bahasa Indonesia (± 700 kata).
ir/indexer.py	Membangun BoW (CountVectorizer) dan index Whoosh, menyimpan model ke index_store/.
ir/searcher.py	Retrieval kandidat Whoosh dan ranking cosine similarity.

Modul	Tanggung jawab
run_test_queries.py	Menjalankan query uji non-interaktif dan menyimpan hasilnya.

2.3 Keputusan Desain

Preprocessing identik untuk dokumen dan query. Ini memastikan token query berada di ruang term yang sama dengan dokumen. Judul diberi bobot dengan mengulangnya dua kali sebelum preprocessing, karena judul biasanya paling merangkum topik. Dua tahap retrieval-then-rank. Whoosh menangani pencarian cepat atas inverted index dan mengembalikan 1000 kandidat dengan model BM25F bawaannya; skor akhir yang dipakai untuk ranking adalah cosine similarity antara vektor BoW query dan vektor BoW dokumen, sesuai ketentuan tugas. Cara ini juga menghindari perhitungan cosine terhadap seluruh 49 ribu dokumen pada setiap query. Index disimpan di disk sehingga menu [1] cukup dijalankan sekali.

3. Implementasi (Kode dan Penjelasan)

3.1 Text Preprocessing

Preprocessing dilakukan berurutan: penghapusan URL dan tag HTML, *case folding* ke huruf kecil, *tokenization* dengan regular expression yang hanya menangkap huruf (angka dan tanda baca dibuang), pembuangan token kurang dari 2 karakter, dan *stopword removal*. Stemming berbasis aturan sederhana tersedia sebagai opsi (USE_STEMMING) namun dimatikan secara default, karena aturannya belum selengkap algoritma Nazief-Adriani dan dapat memotong kata secara keliru (misalnya *pemilihan* menjadi *ilih*).

```
def preprocess(text, use_stemming=None) -> list:
    """Teks mentah -> list token bersih."""
    if use_stemming is None:
        use_stemming = config.USE_STEMMING
    if not isinstance(text, str):
        return []
    text = _URL_RE.sub(" ", text)
    text = _HTML_RE.sub(" ", text)
    text = case_folding(text)
    tokens = tokenize(text)
    tokens = [t for t in tokens if len(t) >= config.MIN_TOKEN_LEN]
    tokens = remove_stopwords(tokens)
    if use_stemming:
        tokens = remove_stopwords([stem(t) for t in tokens])
    return tokens
```

```
def preprocess_to_string(text, use_stemming=None) -> str:
    return " ".join(preprocess(text, use_stemming))
```

Contoh: teks *"KOMPAS.com - Harga BBM naik 10% di https://x.com, menurut Menteri!"* menghasilkan token ['kompas', 'com', 'harga', 'bbm', 'naik', 'menteri'].

3.2 Representasi Dokumen (Bag of Words)

Teks bersih diubah menjadi matriks dokumen-term memakai CountVectorizer. Karena teks sudah diproses, vectorizer hanya memecah berdasarkan spasi (tokenizer=split_tokens) dengan lowercase=False. Parameter min_df=2 membuang term yang hanya muncul di satu dokumen (umumnya typo atau nama unik) untuk menekan ukuran vocabulary. Hasilnya adalah matriks sparse 49.484 × 106.603 dengan 6.311.662 elemen tak nol (sparsity 99,88%), rata-rata 234 token per dokumen.

```
    t0 = time.time()
    vectorizer = CountVectorizer(tokenizer=split_tokens, preprocessor=None,
                                 lowercase=False, token_pattern=None,
                                 min_df=config.BOW_MIN_DF)
    matrix = vectorizer.fit_transform(clean_docs).tocsr()
```

3.3 Indexing dengan Whoosh

Skema Whoosh memuat field content (teks bersih, bertokenisasi spasi, satu-satunya field yang dicari), dataset bertipe ID (dipakai sebagai filter), serta judul, snippet, dan doc_id yang hanya disimpan untuk ditampilkan dan untuk memetakan hasil ke baris matriks BoW. Opsi phrase=False menghemat ruang karena posisi term tidak diperlukan.

```
def build_schema():
    """Skema index Whoosh.
    - content : teks yang SUDAH dipreprocess, dipisah spasi (field yang dicari)
    - doc_id  : nomor baris pada matriks BoW (stored)
    - dataset : sumber dokumen (ID -> dapat dipakai untuk filter)
    - judul, snippet : disimpan untuk ditampilkan pada hasil
    """
    return fields.Schema(
        doc_id=fields.STORED,
        dataset=fields.ID(stored=True),
        judul=fields.STORED,
```

```
    snippet=fields.STORED,
    content=fields.TEXT(analyzer=analysis.RegexTokenizer(r"\S+"), phrase=False),
)



if config.INDEX_DIR.exists():
    shutil.rmtree(config.INDEX_DIR)
config.INDEX_DIR.mkdir(parents=True)
ix = index.create_in(str(config.INDEX_DIR), build_schema())
writer = ix.writer(limitmb=512)
for i, (ds, title, body, clean) in enumerate(
        zip(data["dataset"], data[config.COL_TITLE], data[config.COL_CONTENT], clean_docs)):
    writer.add_document(doc_id=i, dataset=ds, judul=str(title),
                        snippet=_make_snippet(body), content=clean)
    if (i + 1) % 5000 == 0 or i + 1 == n:
        print(f"  Indexing Whoosh: {i + 1}/{n}", end="\r")
print("\n  Commit index ...")
writer.commit()
stats["whoosh_sec"] = time.time() - t0
```

3.4 Pencarian dan Ranking Cosine Similarity

Query dipreprocess, lalu dibentuk query Whoosh berupa gabungan OR atas seluruh term. Whoosh mengembalikan hingga 1000 kandidat (opsional dengan filter dataset). Query diubah menjadi vektor BoW dengan vectorizer yang sama, kemudian cosine similarity dihitung terhadap baris matriks milik kandidat:

$$\cos(q, d) = (q \cdot d) / (\|q\| \cdot \|d\|)$$

Kandidat diurutkan menurun berdasarkan cosine (skor Whoosh dipakai hanya sebagai pemutus seri) dan lima teratas ditampilkan. Jika seluruh term query tidak ada pada vocabulary, sistem menyatakan tidak ada hasil.

```
    def search(self, raw_query: str, top_n: int = None, dataset: str = None):
        """Return (query_tokens, hasil). Hasil = list dict terurut cosine menurun."""
        top_n = top_n or config.TOP_N
        tokens = preprocess(raw_query)
        if not tokens:
            return tokens, []
```

```
# 1) Retrieval kandidat dengan Whoosh (OR antar term query)
q = query.Or([query.Term("content", t) for t in dict.fromkeys(tokens)])
flt = query.Term("dataset", dataset) if dataset else None
with self.ix.searcher() as s:
    hits = s.search(q, limit=config.CANDIDATES, filter=flt)
    cands = [{"doc_id": h["doc_id"], "dataset": h["dataset"], "judul": h["judul"],
              "snippet": h["snippet"], "bm25": float(h.score)} for h in hits]
if not cands:
    return tokens, []

# 2) Representasi BoW query + cosine similarity terhadap kandidat
q_vec = self.vectorizer.transform([" ".join(tokens)])
if q_vec.nnz == 0:                  # semua term query tidak ada di vocabulary
    return tokens, []
rows = [c["doc_id"] for c in cands]
sims = cosine_similarity(q_vec, self.matrix[rows]).ravel()
for c, sc in zip(cands, sims):
    c["cosine"] = float(sc)

# 3) Ranking: cosine menurun (tie-break: skor Whoosh)
cands.sort(key=lambda c: (c["cosine"], c["bm25"]), reverse=True)
return tokens, cands[:top_n]
```

3.5 Antarmuka CLI

main.py menampilkan menu sesuai spesifikasi. Menu [1] memuat dataset dan membangun index beserta ringkasan waktu proses; menu [2] meminta query (dan filter dataset opsional) lalu menampilkan peringkat, dataset, judul, skor, dan cuplikan isi; menu [3] keluar. Bila index sudah ada di disk, menu [2] memuatnya otomatis.

```
=== INFORMATION RETRIEVAL SYSTEM ===
[1] Load & Index Dataset
[2] Search Query
[3] Exit
====================================
```

4. Pengujian Query dan Analisis Hasil

4.1 Skenario Pengujian

Pengujian memakai 10 query yang dijalankan lewat run_test_queries.py: query akademik, berita/politik, hiburan, query bersifat umum yang dapat muncul di banyak dataset, query dengan filter dataset, dan query tanpa kecocokan. Penilaian relevansi dilakukan secara manual berdasarkan judul dan cuplikan isi dokumen. Seluruh nilai pada tabel adalah skor cosine similarity.

4.2 Statistik Index

Metrik	**Nilai**
Jumlah dokumen terindeks	49.484
Ukuran vocabulary BoW (min_df=2)	106.603 term
Elemen tak nol matriks BoW	6.311.662 (sparsity 99,88%)
Rata-rata token per dokumen setelah preprocessing	234
Waktu preprocessing seluruh dokumen	17,7 detik
Waktu pembentukan matriks BoW	6,9 detik
Waktu pembentukan index Whoosh	187,6 detik

Waktu diukur pada komputer penguji dan bergantung pada spesifikasi mesin.

4.3 Hasil Query

Query 1: "kecerdasan buatan"

Token hasil preprocessing: ['kecerdasan', 'buatan']

#	**Dataset**	**Cosine**	**Judul**
1	etd-ugm	0.5687	INTERNSHIP REPORT: PT KPMG SIDDHARTA ADVISORY “HOW ARTIFICIAL INTELLIGENCE CAN AID IN VALUATION SERVICES”
2	mojok	0.5583	Kecerdasan Buatan Bisa Nggak Cerdas Lagi kalau Gantikan PNS dan Hadapi Birokrasi Fotokopi
3	etd-ugm	0.5507	THE ARTIFICIAL INTELLIGENCE PATENT TOWARDS ITS INVENTIONS AND THE REGULATION FOR THE USE OF ARTIFICIAL INTELLI
4	etd-ugm	0.4153	Korelasi Antara Kreativitas Pengalaman Seni Komunitas SAGA dengan Kecerdasan Majemuk

#	Dataset	Cosine	Judul
5	etd-usk	0.3728	PERBANDINGAN HASIL TANGKAPAN UMPAN PANCING GURITA SEMI BUATAN DAN BUATAN DI KECAMATAN SALANG KABUPATEN SIMEULU

Analisis: Dokumen teratas membahas kecerdasan buatan (laporan magang tentang AI, artikel Mojok tentang AI dan birokrasi, tesis hak paten AI). Peringkat 4 dan 5 kurang relevan: kata *kecerdasan* dan *buatan* dipakai pada konteks lain (kecerdasan majemuk, umpan pancing buatan). Ini menunjukkan BoW tidak menangkap frasa maupun makna.

Query 2: "pembelajaran matematika siswa SMP"

Token hasil preprocessing: ['pembelajaran', 'matematika', 'siswa', 'smp']

#	Dataset	Cosine	Judul
1	mojok	0.6743	Pembelajaran Matematika Seharusnya SESAT, Maksudnya Seru, Serius, Aplikatif, dan Transformatif
2	etd-usk	0.6597	KECEMASAN MATEMATIKA SISWA SMP SELAMA PEMBELAJARAN REMEDIAL BERBASIS E-LEARNING
3	etd-usk	0.6109	MENGIDENTIFIKASI SOCIOMATHEMATICAL NORM SISWA MELALUI PROJEK GAME DENGAN KONTEKS STUNTING BERBANTUAN AUGMENTE
4	etd-usk	0.6031	EFEKTIVITAS PENDEKATAN MATEMATIKA REALISTIK UNTUK MENINGKATKAN LITERASI NUMERASI SISWA SMP
5	etd-usk	0.5361	HASIL BELAJAR MATEMATIKA DAN KETERLIBATAN SISWA MELALUI PENERAPAN MODEL PEMBELAJARAN FLIPPED CLASSROOM DI SMA

Analisis: Seluruh hasil relevan dengan pembelajaran matematika. Empat dari lima berasal dari etd-usk, sesuai karakter tesis pendidikan; artikel opini Mojok tentang pembelajaran matematika juga muncul di peringkat 1.

Query 3: "korupsi pejabat negara"

Token hasil preprocessing: ['korupsi', 'pejabat', 'negara']

#	Dataset	Cosine	Judul
1	kompas	0.5941	Perang Memberantas Korupsi pada Masa Orde Lama
2	tempo	0.4254	Mengapa Negara-negara Nordik Selalu Masuk Daftar Negara Paling Bahagia?

#	Dataset	Cosine	Judul
3	mojok	0.4239	Brutalnya Hidup di Negara kayak Indonesia: Negara ‘Survival of The Fittest’
4	etd-usk	0.3986	PERTANGGUNGJAWABAN PIDANA PENETAPAN DISKRESI OLEH PEJABAT PEMERINTAH DALAM KAITANNYA DENGAN TINDAK PIDANA KORU
5	tempo	0.3960	Ketua KPK Memastikan Tetap Berwenang Menindak Kasus Korupsi di BUMN

Analisis: Peringkat 1, 4, dan 5 relevan (korupsi, pejabat pemerintah, KPK). Peringkat 2 dan 3 membahas negara secara umum (negara Nordik, kritik sosial) tanpa unsur korupsi. Karena BoW memakai frekuensi mentah tanpa IDF, kata umum *negara* yang berulang dapat menaikkan skor dokumen yang kurang relevan.

Query 4: "harga BBM naik"

Token hasil preprocessing: ['harga', 'bbm', 'naik']

#	Dataset	Cosine	Judul
1	mojok	0.6191	Harga BBM Naik, Jokowi dan Sri Mulyani Sukses “Menistakan” Harga Diri Rupiah dan Pancasila
2	kompas	0.5540	Libur Waisak, Harga BBM di SPBU Pertamina, Shell, dan BP Stabil
3	tempo	0.5337	Pertamina Turunkan Harga BBM Non-subsidi Pertamax dan Dex Series, Kok Bisa?
4	kompas	0.5274	Perbandingan Harga BBM Pertamina, Shell, dan BP AKR per 1 Mei 2025
5	kompas	0.5251	Harga BBM Pertamina Mei 2025 di Seluruh Indonesia, Cek Daftarnya

Analisis: Semua hasil relevan: harga BBM pada berita Kompas dan Tempo, serta opini Mojok. Query menghasilkan campuran sumber berita yang wajar, termasuk artikel satir bernada opini.

Query 5: "lagu anime"

Token hasil preprocessing: ['lagu', 'anime']

#	Dataset	Cosine	Judul
1	mojok	0.7822	7 Lagu Anime yang Pasti Bikin Kamu Makin Semangat
2	mojok	0.6176	7 Lagu Luar Negeri yang Punya Vibes Mirip Lagu Indonesia
3	mojok	0.6072	5 Rekomendasi Lagu The Rain yang Underrated
4	mojok	0.5757	Rekomendasi Lagu-lagu Musisi Lampung yang Patut Didengar Selain Kangen Band

#	Dataset	Cosine	Judul
5	mojok	0.5689	6 Lagu SNSD yang Underrated, Wajib Masuk Playlist-mu

Analisis: Seluruh lima hasil berasal dari Mojok, dan dokumen peringkat 1 ("7 Lagu Anime yang Pasti Bikin Kamu Makin Semangat") merupakan padanan terdekat. Topik hiburan populer memang hanya terwakili oleh dataset ini.

Query 6: "dampak perubahan iklim terhadap pertanian"

Token hasil preprocessing: ['dampak', 'perubahan', 'iklim', 'pertanian']

#	Dataset	Cosine	Judul
1	etd-ugm	0.6008	Petani dan Perubahan Iklim
2	etd-usk	0.4792	GAMBARAN PERSEPSI MASYARAKAT GAMPONG ALUE DEAH TEUNGOH KECAMATAN MEURAXA KOTA BANDA ACEH TENTANG RISIKO KESEHA
3	etd-ugm	0.4677	Dampak Perubahan Iklim dan Proyeksi Kebutuhan Air Tanaman Padi di Kabupaten Batang Hari Provinsi Jambi
4	etd-usk	0.4673	HUBUNGAN PENGETAHUAN DAN SIKAP TENTANG DAMPAK PERUBAHAN IKLIM DI SEKTOR KESEHATAN TERHADAP PERILAKU TENAGA KES
5	etd-ugm	0.4131	PENGARUH PERUBAHAN IKLIM TERHADAP KETERSEDIAAN AIR BERSIH DAN KEJADIAN DIARE: A SCOPING REVIEW

Analisis: Seluruh hasil berasal dari tesis (etd-ugm dan etd-usk) dan membahas dampak perubahan iklim. Peringkat 1 membahas petani dan perubahan iklim; peringkat 2 membahas persepsi risiko kesehatan akibat perubahan iklim sehingga hanya relevan sebagian terhadap sektor pertanian.

Query 7: "pemilihan presiden"

Token hasil preprocessing: ['pemilihan', 'presiden']

#	Dataset	Cosine	Judul
1	etd-ugm	0.6726	PENGARUH PEMILIHAN PRESIDEN 2004-2019 TERHADAP RETURN PERDAGANGAN SAHAM DI INDONESIA
2	tempo	0.5808	Pemilihan Presiden Korea Selatan Setelah Pemakzulan Yoon Suk Yeol
3	tempo	0.5623	Pemilihan Presiden Korea Selatan: Kandidat dan Permohonan Maaf Yoon Suk Yeol

#	Dataset	Cosine	Judul
4	etd-usk	0.4895	URGENSI PENCALONAN PRESIDEN DAN WAKIL PRESIDEN INDEPENDENT DI INDONESIA
5	mojok	0.4825	Ketika Seorang Presiden Berpayung Hitam Melintas di Persawahan pada Saat Hujan

Analisis: Peringkat 1-4 relevan dengan pemilihan presiden (tesis, berita Tempo tentang Korea Selatan, tesis USK). Peringkat 5 dari Mojok adalah esai tentang presiden berpayung hitam dan bukan tentang pemilihan; kata *presiden* mendominasi skor.

Query 8: "sepak bola timnas"

Token hasil preprocessing: ['sepak', 'bola', 'timnas']

#	Dataset	Cosine	Judul
1	mojok	0.6165	Timnas Indonesia U-23 Bersama Shin Tae-yong Membuat Saya Merasakan Cinta Sekali Lagi
2	etd-ugm	0.5746	Cara Kerja Wartawan Sepak Bola Indonesia (Studi Etnografi Adaptasi Wartawan Desk Sepak Bola di Jawa Pos Radar
3	mojok	0.5514	Sepak Bola Wanita Tak Semembosankan yang Dibayangkan
4	etd-ugm	0.5340	Rencana Bisnis Pengembangan Media Garis Tengah Football Menjadi Akademi Sepak Bola
5	etd-usk	0.5083	HUBUNGAN KESEIMBANGAN DINAMIS, KOORDINASI MATA-KAKI DAN KONSENTRASI DENGAN KETERAMPILAN SEPAK BOLA PEMAIN JUNI

Analisis: Hasil berupa campuran artikel Mojok tentang Timnas, tesis jurnalisme olahraga, dan tesis keolahragaan (kebugaran). Relevansi bervariasi karena dataset berita olahraga tidak dominan pada koleksi ini.

Query 9: "kecerdasan buatan" (filter: kompas)

Token hasil preprocessing: ['kecerdasan', 'buatan']

#	Dataset	Cosine	Judul
1	kompas	0.2619	Kenali Perbedaan Zat Aditif Alami dan Buatan beserta Contohnya
2	kompas	0.2457	"Bapak AI" Peringatkan Ancaman Kecerdasan Buatan "Ambil Alih" Manusia
3	kompas	0.2257	5 Hewan Peliharaan Paling Cerdas, Ada Anjing dan Kucing

#	Dataset	Cosine	Judul
4	kompas	0.2107	Hindari Kebiasaan Makan Ini, Bisa Merusak Kesehatan Usus
5	kompas	0.1919	Riset: AI Makin Canggih, tapi Juga Makin "Halu"

Analisis: Dengan filter dataset Kompas, skor cosine rendah (0,19-0,26). Hanya dua dokumen yang membahas AI secara langsung; sisanya muncul karena kata *buatan* atau *cerdas*. Kompas lebih sering menulis "AI" daripada "kecerdasan buatan", sehingga terjadi *vocabulary mismatch*. Skor rendah dapat menjadi indikator kecocokan yang lemah.

Query 10: "zzqxv plorf"

Token hasil preprocessing: ['zzqxv', 'plorf']

(tidak ada hasil)

Analisis: Term tidak ada pada vocabulary, sehingga sistem menampilkan pesan bahwa tidak ada dokumen yang cocok tanpa menimbulkan error.

4.4 Analisis Umum

Kekuatan. Query dengan istilah spesifik (*lagu anime*, *harga BBM naik*, *pembelajaran matematika siswa SMP*) menghasilkan dokumen yang tepat di peringkat atas. Distribusi sumber hasil mengikuti karakter dataset: query akademik didominasi tesis, query berita dan hiburan didominasi Kompas, Tempo, dan Mojok. Waktu pencarian pada pengujian berada pada kisaran puluhan milidetik.

Kelemahan. (1) Frekuensi mentah tanpa IDF membuat kata umum seperti *negara* dan *presiden* berpengaruh besar, sehingga dokumen yang kurang relevan kadang menembus lima besar. (2) BoW mengabaikan urutan kata, sehingga frasa *kecerdasan buatan* tidak dibedakan dari kemunculan terpisah kedua kata itu. (3) Tidak ada penanganan sinonim atau singkatan (AI vs kecerdasan buatan). (4) Tanpa stemming, bentuk *pertanian* dan *petani* dianggap term berbeda.

Saran pengembangan. Mengganti pembobotan menjadi TF-IDF (TfidfVectorizer), menambah n-gram bigram, memakai stemmer Nazief-Adriani yang lengkap, menambah kamus sinonim/ekspansi query, dan membuat evaluasi kuantitatif (precision@5, MAP) dengan penilaian relevansi yang lebih besar.

5. Kesimpulan

Proyek ini menghasilkan sistem IR berbasis CLI yang mengindeks 49.484 dokumen dari lima sumber teks berbahasa Indonesia. Pipeline lengkap berhasil diimplementasikan: preprocessing (case folding, tokenisasi, stopword removal), representasi Bag of Words dengan CountVectorizer, pembentukan index dengan Whoosh, pencarian berdasarkan query pengguna, dan ranking lima dokumen teratas dengan cosine similarity. Pengujian menunjukkan sistem efektif untuk query dengan istilah spesifik dan mampu menangani query tanpa kecocokan, namun masih dibatasi oleh pembobotan frekuensi mentah dan

ketiadaan pemahaman semantik. Pengembangan lanjutan berupa TF-IDF, stemming yang lebih baik, dan evaluasi kuantitatif dapat meningkatkan ketepatan pencarian.